Universidade do Minho
Escola de Engenharia

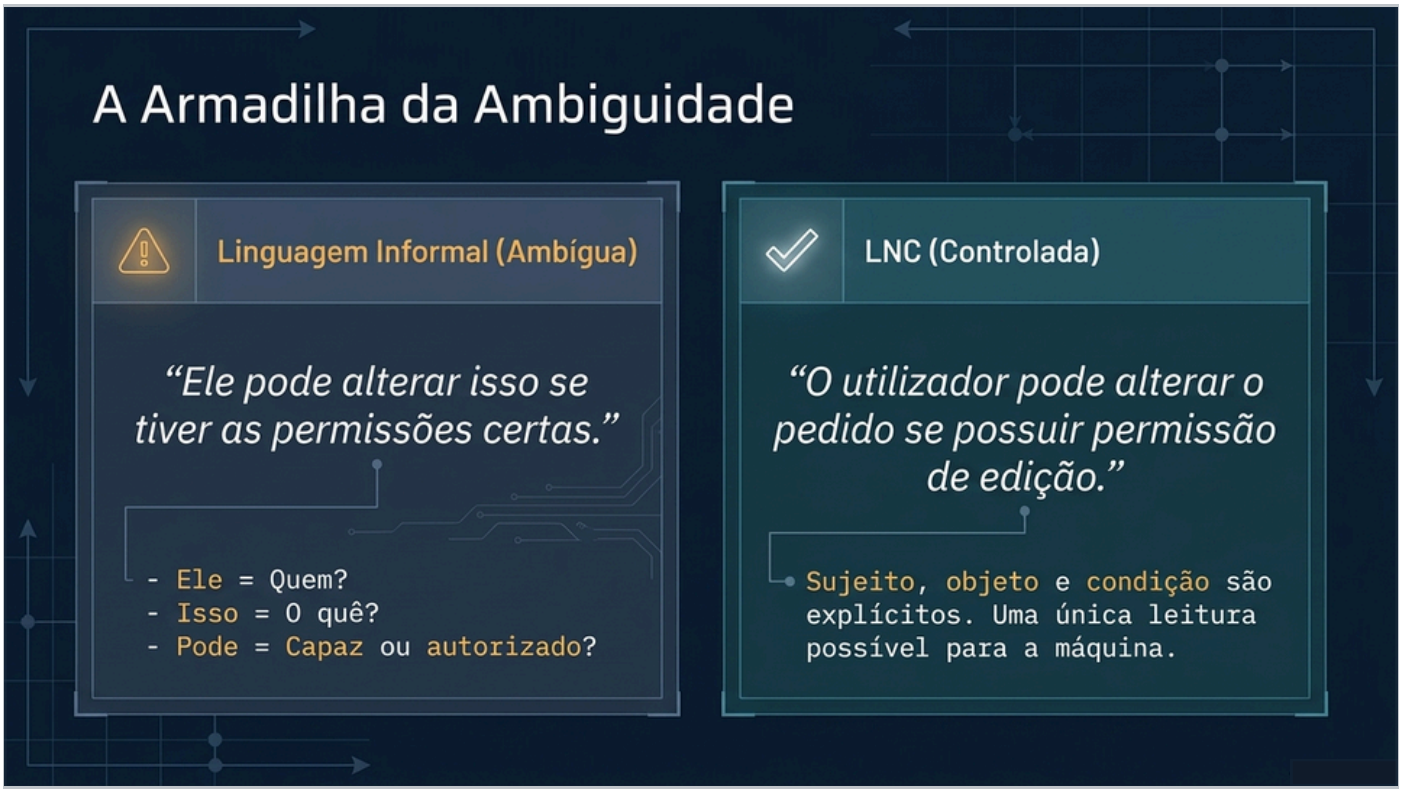
Projeto em Informática

Linguagens Naturais Controladas (LNC)

Controlo de Acessos e Auditoria Interna

Eduarda Pereira - PG61516
Gonçalo Magalhaẽs - PG61524

Bom dia a todos. Iremos apresentar o nosso Projeto de Engenharia Informática, focado em Linguagens Naturais Controladas (LNC). O objetivo é criar um 'Português Determinístico' para Autorização Corporativa e Controle de Acesso, garantindo que as regras de segurança sejam compreensíveis para humanos e executáveis por computadores. O projeto atua assim como uma ponte entre Pesquisa Lógica e Arquitetura Computacional.



No nosso cotidiano, usamos uma linguagem informal que depende do contexto, mas isso pode confundir máquinas. Por exemplo, a frase "Ele pode alterar isso se tiver as permissões certas" é ambígua para um sistema. A LNC resolve esse problema ao traduzir a frase para uma linguagem controlada: "O utilizador pode alterar o pedido se possuir permissão de edição". Essa tradução torna sujeito, objeto e condição claros, garantindo uma única interpretação para a máquina e eliminando dúvidas.

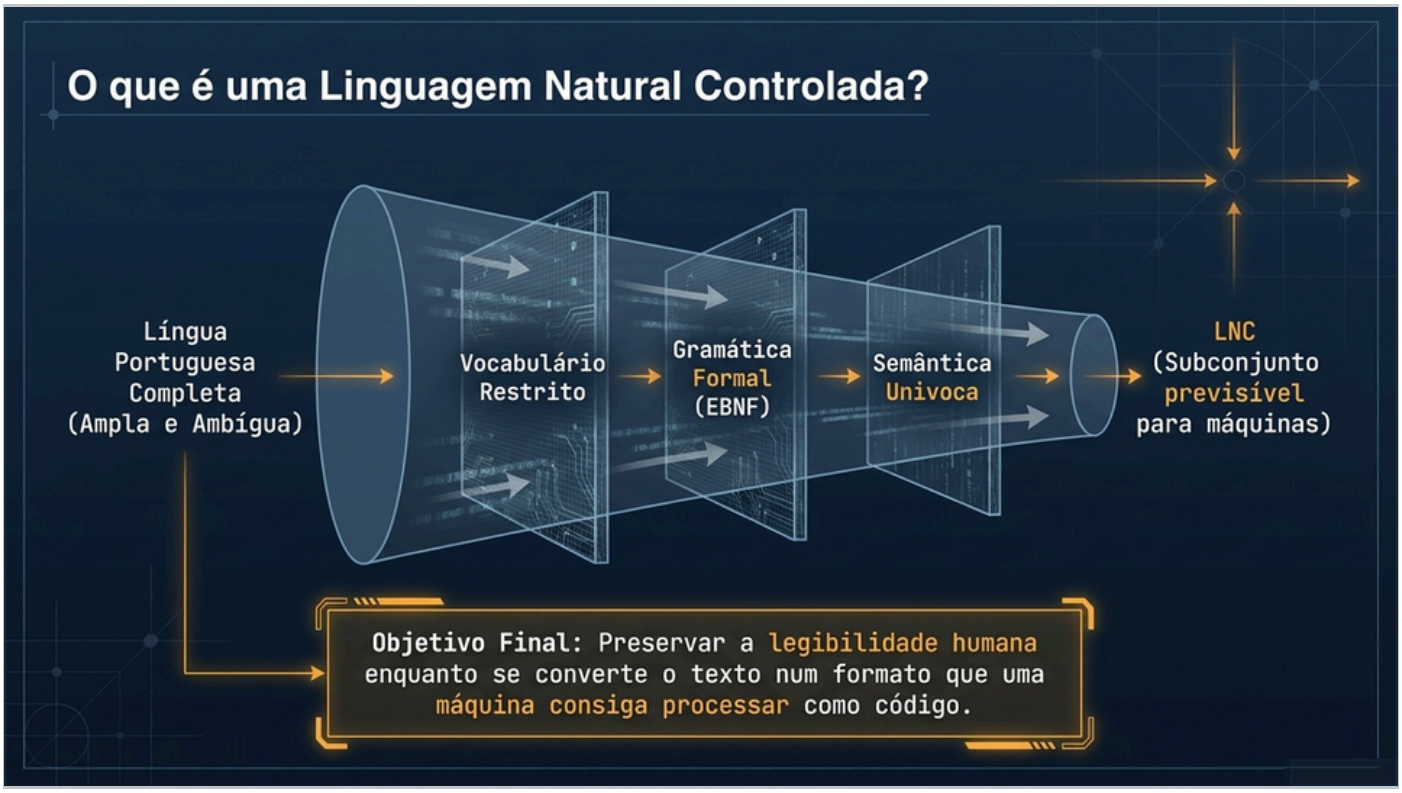


Chegados a este ponto, é natural perguntarem: porque é que não usamos simplesmente a IA para traduzir o texto para código?

O problema está no risco de alucinação. Os LLMs baseiam-se em inferência probabilística. Quando estamos a lidar com políticas de segurança corporativa rigorosas, a probabilidade simplesmente não é suficiente. Precisamos de garantias matemáticas.

Se usarmos a abordagem convencional de um LLM, em que traduzimos texto livre diretamente para código, estamos a criar uma 'Caixa Negra' (Black Box). Esta abordagem sofre de falhas graves cada vez que o modelo é corrido.

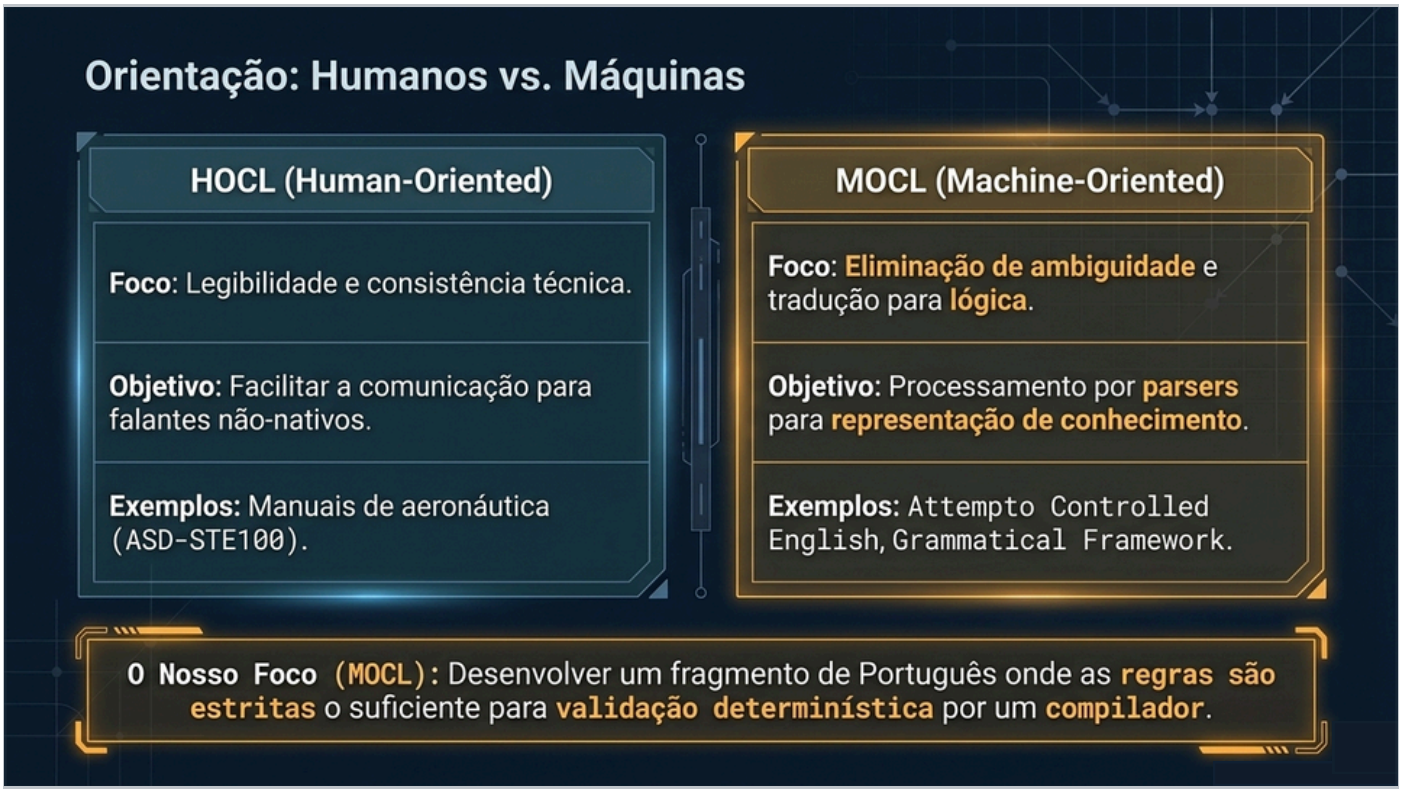
A nossa abordagem com a LNC funciona pelo caminho oposto, atuando como uma 'Caixa Branca' (White Box). A LNC serve de representação intermédia: o texto livre passa para LNC, e só depois é executado.
3



Mas afinal, como se constrói e o que é tecnicamente esta Linguagem Natural Controlada? Para visualizarem o processo, pensem num funil.

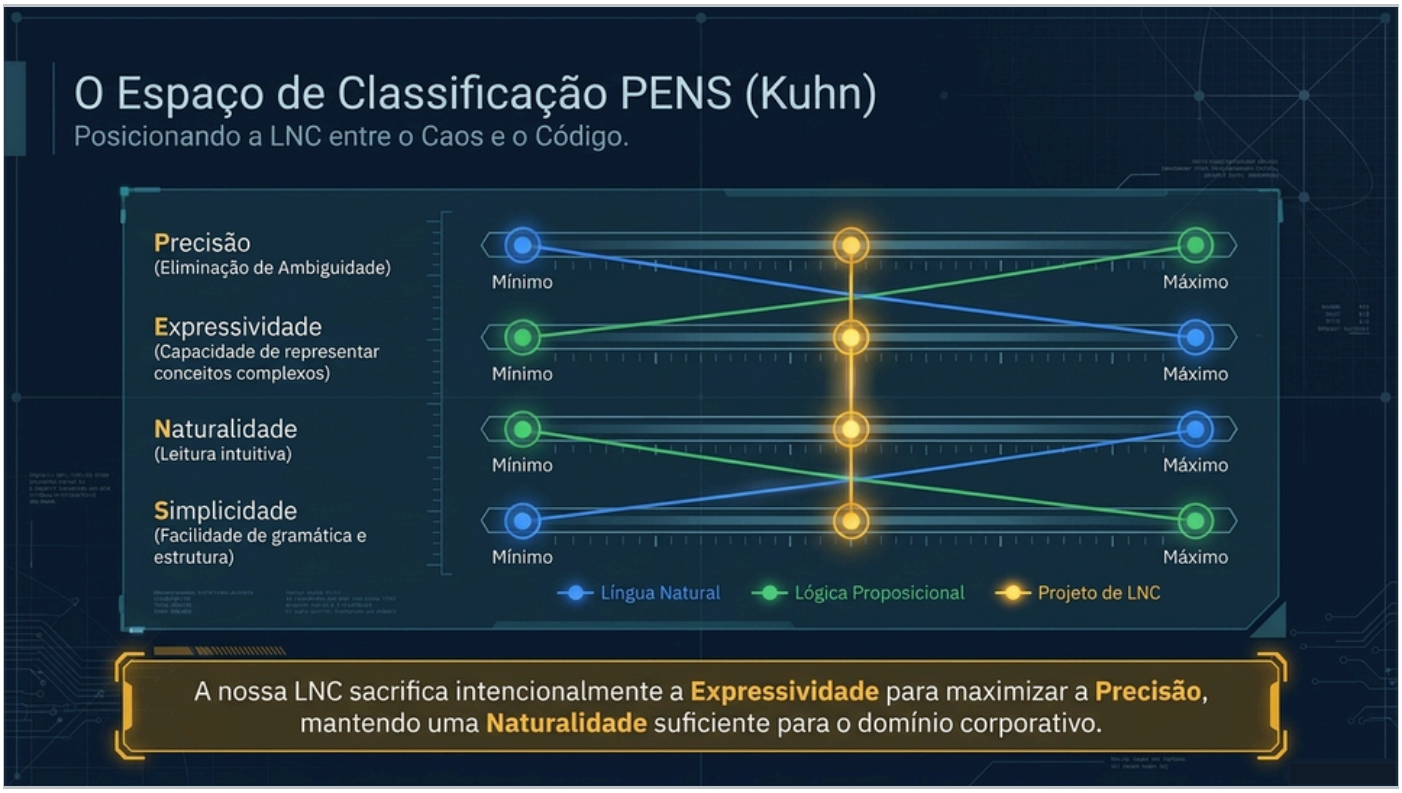
Na entrada do funil, temos a Língua Portuguesa Completa, que é ampla e ambígua.
Para a tornarmos processável para um computador, aplicamos três filtros de restrição:
-Impor um Vocabulário Restrito(onde cada palavra tem apenas um significado)
-Aplicar uma Gramática Formal
-Garantir uma Semântica Unívoca(onde não há duplo sentido)

O que sai na outra ponta do funil é a nossa LNC: um subconjunto da língua que é inteiramente previsível para as máquinas.
O nosso objetivo final com este design é simples mas poderoso: LER no powerpoint



Neste projeto, começámos por definir o tipo de linguagem controlada que queríamos construir. Existem duas orientações principais: as HOCL, desenhadas para facilitar a leitura humana e as MOCL, orientadas para as máquinas.
O nosso foco recai inteiramente nas MOCL, com o foco de eliminar a ambiguidade e tradução para lógica, permitindo o processamento por parsers para representação de conhecimento.

Para o nosso projeto, isto significa desenvolver um fragmento de Português com regras estritas o suficiente para garantir uma validação determinística por um compilador.



Para posicionarmos a nossa linguagem entre o 'Caos' da língua natural e o 'Código' puro, utilizámos o Espaço de Classificação PENS, proposto por Tobias Kuhn. Este espaço avalia Precisão, Expressividade, Naturalidade e Simplicidade.
Como podem ver no gráfico, a nossa LNC faz uma escolha deliberada: LER parte de baixo do powerpoint



Como é que impomos esta precisão? Através de duas categorias de regras.
As Regras Proscritivas, que definem o que evitar: proibimos pronomes vagos como 'Ele' ou 'Isso' porque não podem ser resolvidos deterministicamente, eliminamos o uso de sinónimos, exigindo que um conceito corresponda a uma única palavra, e bloqueamos subordinações longas.

Por outro lado, as Regras Prescritivas, impõem padrões obrigatórios: uma estrutura rígida de Sujeito, Verbo e Objeto, o uso estrito de dicionários de domínio pré-aprovados e a declaração explícita de todas as dependências ou condições.

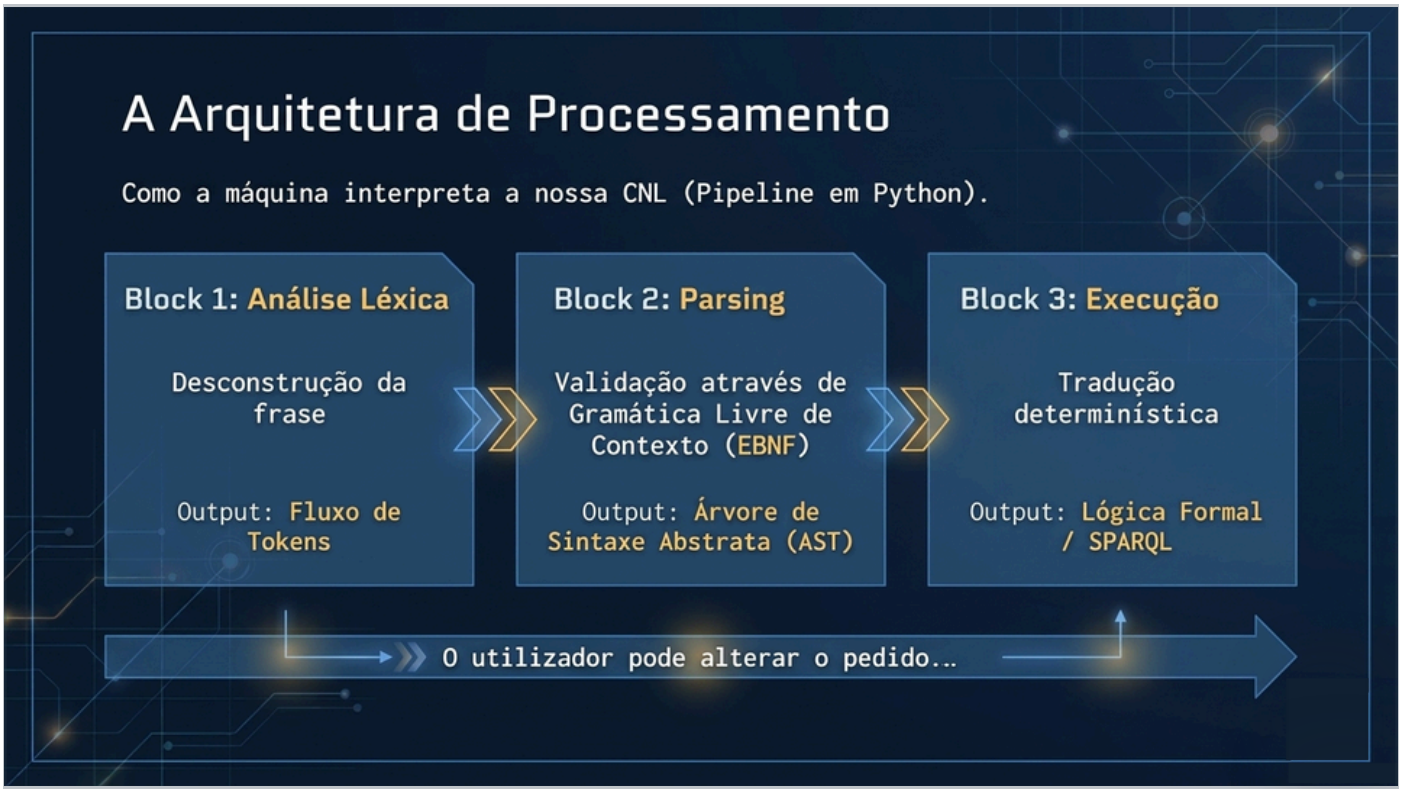


Aplicámos estas regras a um domínio alvo específico: as Políticas de Controlo de Acesso.
O nosso fragmento de Português.....(ler)
O modelo liga um Agente (como 'O utilizador') a uma Relação Deôntica que pode ser uma Permissão, Proibição ou Obrigação ('pode', 'não pode', 'deve'). Esta relação atua sobre um Recurso ('o pedido') e pode estar dependente de uma Guarda ou Condição ('se possuir permissão de edição').

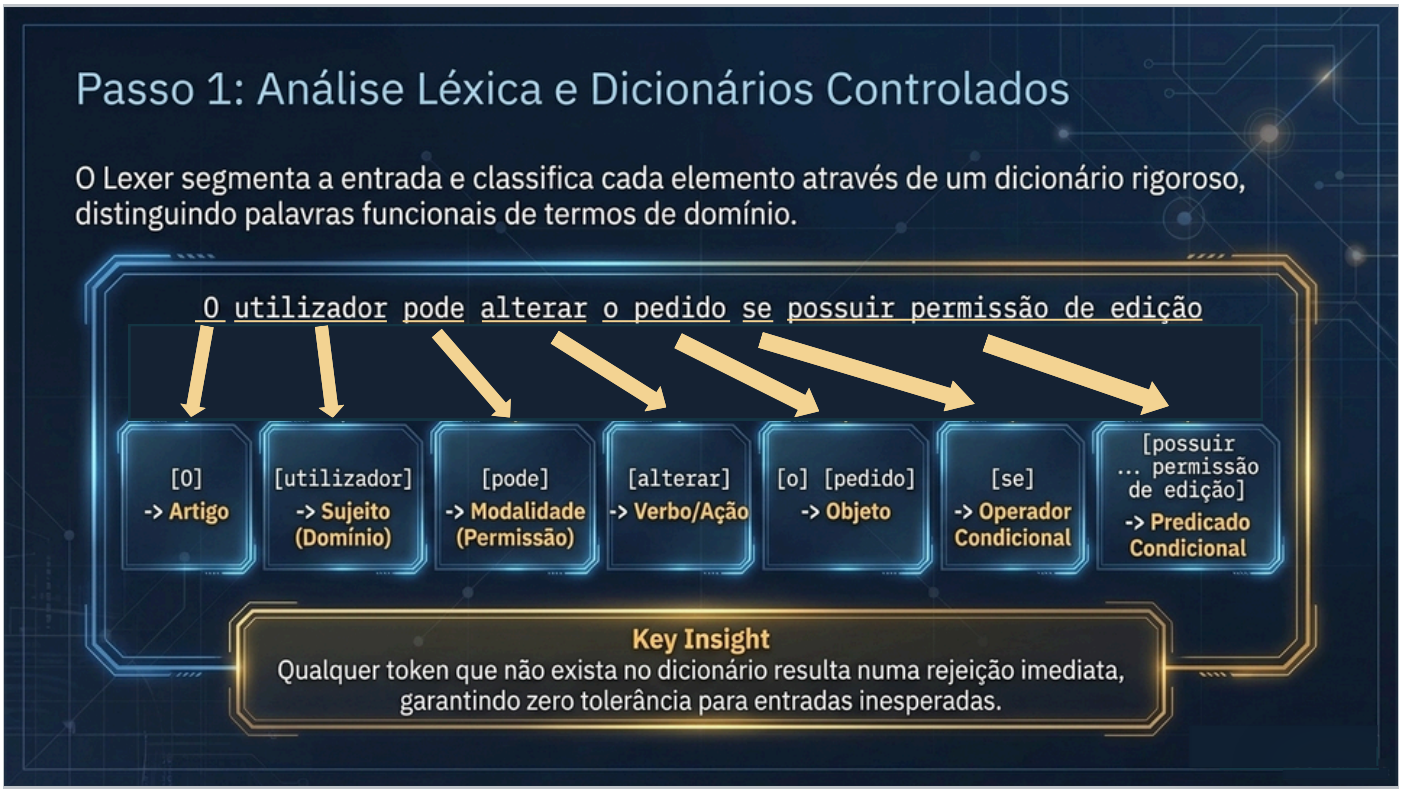
Ler parte de baixo



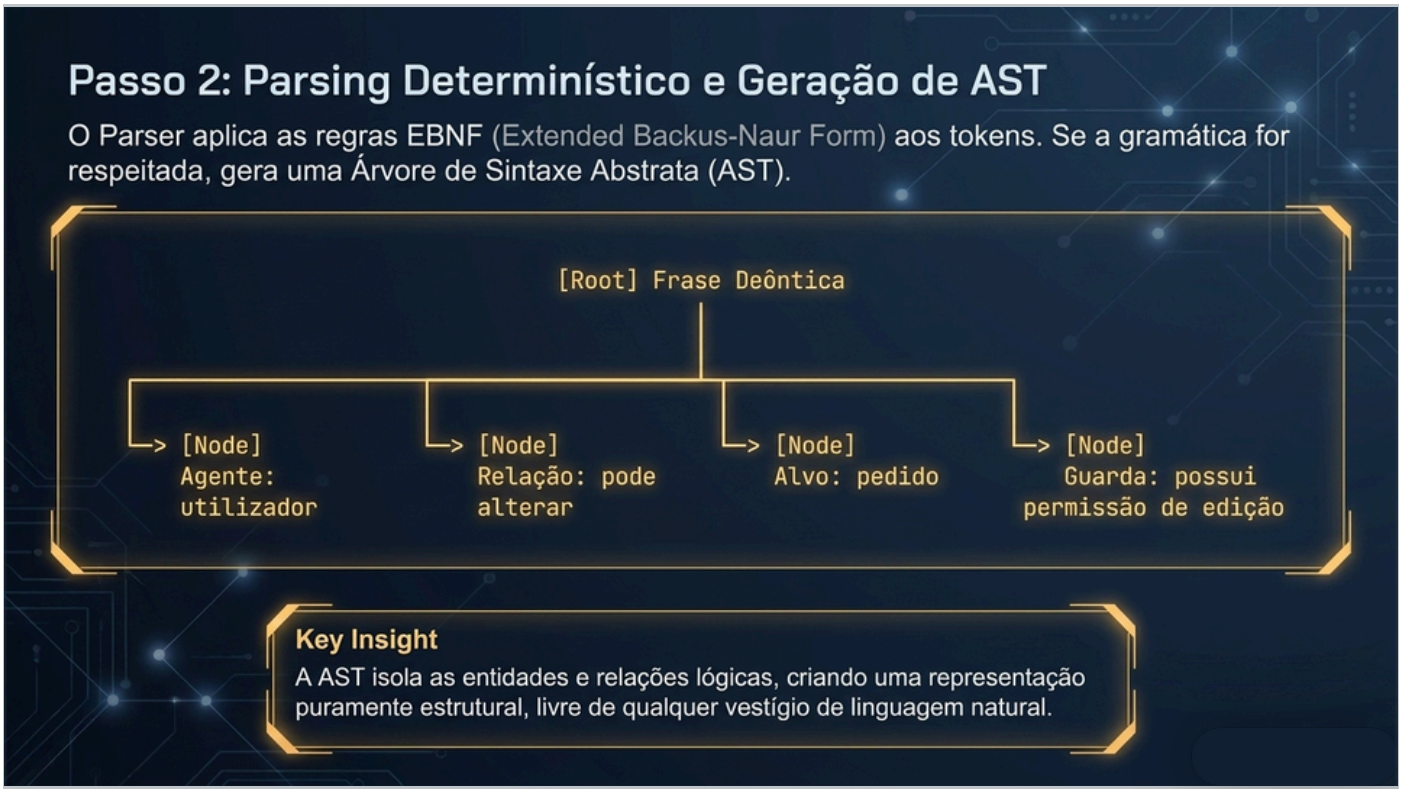
Aplicámos também estas regras a um segundo domínio alvo: a Auditoria e Monitorização de Risco. O nosso fragmento de Português foi otimizado para expressar regras de risco e consultas analíticas no grande retalho. O modelo liga um Evento Condicional (como 'Se um operador anular mais de 5 talões no mesmo turno') a um Comportamento ou Ação ('o sistema envia um email de alerta com o relatório'). Esta ação é direcionada a uma Consequência ou Alvo ('para o supervisor') e pode ser refinada por uma Janela Temporal ou Métrica ('no último mês' ou 'superior a 150 euros'). Este foco garante que a auditoria de risco é imutável e auditável em tempo real.



Para que a máquina interprete esta LNC, construímos um pipeline em Python dividido em três blocos.
O Bloco 1 faz a Análise Léxica, desconstruindo a frase num fluxo de tokens.
O Bloco 2 é o Parsing, que valida os tokens através de uma Gramática Livre de Contexto, gerando uma Árvore de Sintaxe Abstrata.
O Bloco 3 é a Execução, onde ocorre a tradução determinística para Lógica Formal ou SPARQL.



Entrando no Bloco 1, temos a Análise Léxica. Aqui, o nosso Lexer segmenta a entrada e classifica cada elemento com base num dicionário rigoroso. Como podem ver no exemplo: 'utilizador' é classificada como o Sujeito do domínio,
'pode' como a Modalidade de permissão etc.
A regra de ouro aqui é a tolerância zero: LER powerpoint



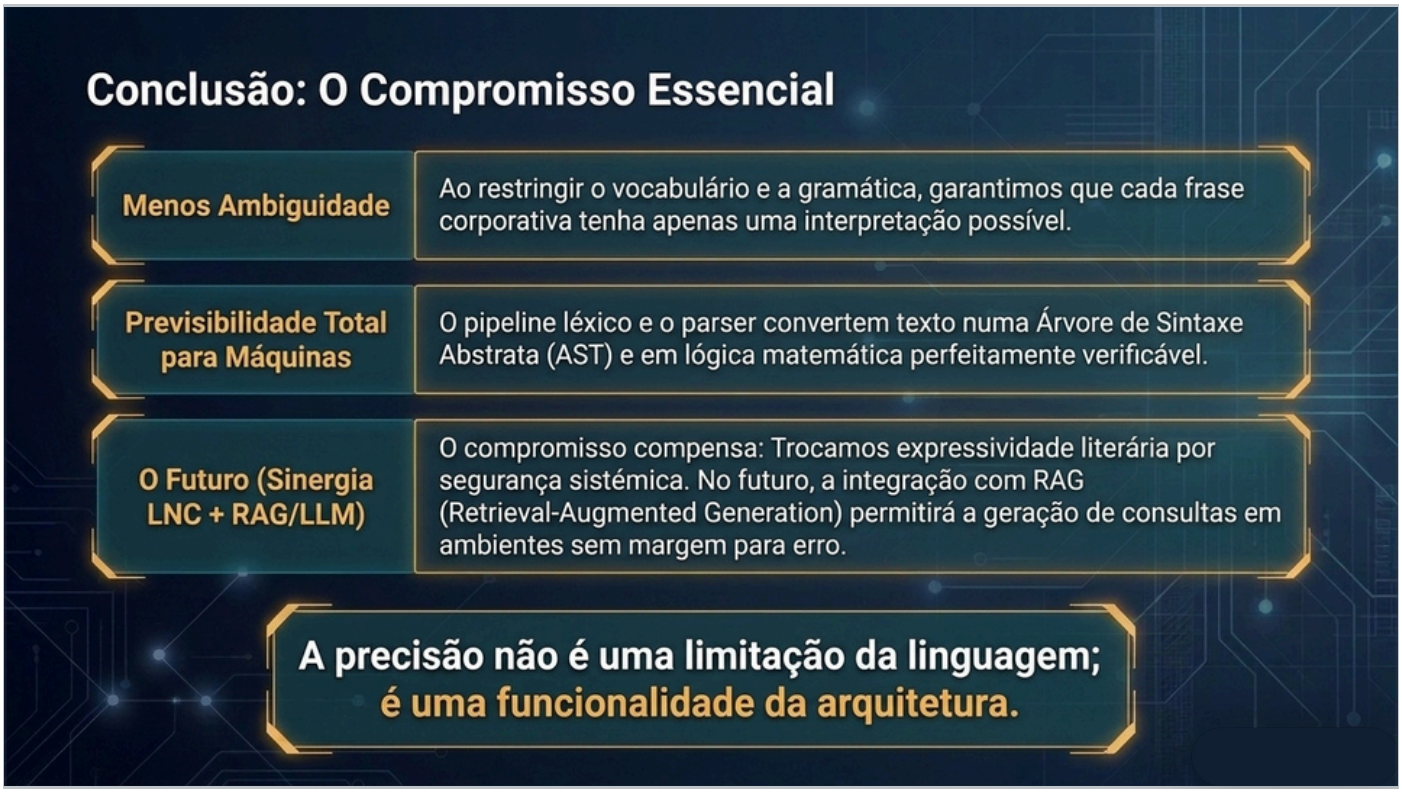
No Passo 2, o Parser recebe estes tokens e aplica regras EBNF, ou seja, regras formais de gramática. Se a estrutura da frase respeitar a gramática, o sistema gera uma AST. O aspeto mais importante deste passo é que .... LER POWERPOINT



Por fim, no Passo 3, esta árvore é consumida por um compilador ou motor de regras. Esta estrutura intermédia é convertida em consultas acionáveis – como código SPARQL – ou em provas lógicas. O contexto académico atual, suportado por investigações de autores como Luz e Caio, demonstra que esta representação intermédia é a chave para interagir com Grafos de Conhecimento com 100% de precisão.



Tudo isto leva-nos a um novo paradigma. Se compararmos abordagens,
A Linguagem Natural processada diretamente por um LLM tem alta legibilidade humana, mas baixa precisão determinística.
Por outro lado, o código puro, como Python ou SPARQL, tem alta precisão, mas baixa legibilidade e uma barreira de entrada alta.
O nosso projeto de LNC oferece o melhor dos dois mundos: Alta legibilidade humana e Alta precisão determinística.
A LNC funciona como o 'elo perdido': modelos recentes provam que utilizar LLMs para gerar texto em LNC, em vez de código complexo como SPARQL, reduz drasticamente tanto as necessidades de dados de treino como os erros de sintaxe.



Para concluir, o nosso trabalho demonstra que este compromisso essencial compensa. Primeiro, obtemos Menos Ambiguidade: ao restringir o vocabulário e a gramática, garantimos que cada frase corporativa tem apenas uma interpretação possível. Segundo, atingimos Previsibilidade Total: o nosso pipeline converte texto em lógica matemática perfeitamente verificável. Trocamos expressividade literária por segurança sistémica, e no futuro, a sinergia entre LNC e sistemas RAG com LLMs permitirá gerar consultas em ambientes de segurança onde não há margem para erro. A grande lição é que a precisão não é uma limitação da linguagem; é uma funcionalidade desenhada na arquitetura. Obrigado pela vossa atenção.